Ciência de Dados e Inteligência Artificial

Fase 1

Nome do estudante: Guilherme Ruiz Lizardo

Síntese do conjunto de dados como apresentado na sua origem:

O conjunto de dados escolhido é o **Default of Credit Card Clients**, disponível no UCI Machine Learning Repository. Foi criado por I-Cheng Yeh e publicado em 2009 no artigo "The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients" (Expert Systems with Applications). O dataset reúne informações de 30.000 clientes de cartão de crédito de um banco taiwanes, coletadas entre abril e setembro de 2005. Para cada cliente, há dados demográficos (sexo, idade, escolaridade e estado civil), o limite de crédito concedido, o histórico de pagamento mês a mês (se pagou em dia, usou rotativo ou atrasou), os valores das faturas e os valores efetivamente pagos em cada um dos seis meses. A variável alvo registra se aquele cliente veio a se tornar inadimplente no mês seguinte (outubro/2005).

Escolhi esse dataset por ter relação direta com a minha área de atuação profissional. Trabalho como Analista de Dados no Sicoob, que é uma cooperativa de crédito, então o problema de prever inadimplência faz parte do dia a dia do setor financeiro. Além disso, o dataset tem características que facilitam a exploração: não possui nenhum valor nulo, tem um volume bom de registros (30 mil) e mistura variáveis categóricas com numéricas, o que permite aplicar diferentes técnicas de análise. O fato de a taxa de inadimplência ser de cerca de 22% também é interessante, porque cria um cenário de classes desbalanceadas que é muito comum em problemas reais de crédito.

Por fim, o dataset é licenciado sob Creative Commons (CC BY 4.0), o que permite o uso acadêmico sem restrições, e conta com um artigo científico de referência que detalha a metodologia de coleta dos dados e compara diferentes técnicas de mineração de dados aplicadas a ele.

Quantidade de linhas e colunas do conjunto de dados:

Finalidade do dataset: Prever se um cliente de cartão de crédito vai se tornar inadimplente no mês seguinte, a partir de dados demográficos e do histórico de pagamentos dos últimos seis meses.
Linhas: 30.000 (cada linha é um cliente diferente).
Colunas: 25 no total (1 coluna de ID, 23 variáveis explicativas e 1 variável alvo).
Formato: O arquivo original está em formato XLS (Excel). Também é possível encontrar versões em CSV no Kaggle.
Valores nulos: Nenhum. Todas as 25 colunas estão 100% preenchidas.

Escolha pelo menos 10 colunas totalmente preenchidas (as mais importantes) e, para cada coluna (inclusive para a coluna alvo):

Selecionei 11 colunas para a análise: as 5 variáveis demográficas (LIMIT_BAL, SEX, EDUCATION, MARRIAGE, AGE), 3 variáveis de histórico de pagamento (PAY_0, PAY_2, PAY_3), 1 de valor de fatura (BILL_AMT1), 1 de valor pago (PAY_AMT1) e a coluna alvo (default payment next month). Abaixo, detalho cada uma:

▶️ **LIMIT_BAL**

O que representa: Representa o montante total de crédito concedido ao cliente, em dólares taiwaneses (NT$). Esse valor inclui tanto o crédito individual quanto o crédito suplementar/familiar.
Tipo de dados: Numérico
Valores válidos: Valores inteiros positivos. No dataset, variam de 10.000 a 1.000.000 NT$.
Valores distintos: 81
Menor valor: 10.000 | **Maior valor:** 1.000.000 | **Moda:** 50.000
Média: 167.484,32 | **Desvio-padrão:** 129.747,66 | **Mediana:** 140.000,00

▶️ SEX
O que representa: Indica o sexo biológico do cliente.
Tipo de dados: Nominal
Valores válidos: 1 = Masculino, 2 = Feminino.
Valores distintos: 2
Menor valor: 1 | **Maior valor:** 2 | **Moda:** 2 (Feminino — 60,4%)
Média: 1,60 | **Desvio-padrão:** 0,49 | **Mediana:** 2,00

▶️ EDUCATION
O que representa: Grau de escolaridade do cliente. A documentação original define quatro categorias, mas no dataset real aparecem também os valores 0, 5 e 6, que não possuem descrição oficial e provavelmente representam categorias não documentadas ou erros de cadastro.
Tipo de dados: Ordinal
Valores válidos: 1 = Pós-graduação, 2 = Universidade, 3 = Ensino médio, 4 = Outros, 0/5/6 = Não documentados.
Valores distintos: 7
Menor valor: 0 | **Maior valor:** 6 | **Moda:** 2 (Universidade — 46,8%)
Média: 1,85 | **Desvio-padrão:** 0,79 | **Mediana:** 2,00

▶️ MARRIAGE
O que representa: Estado civil do cliente. Assim como em EDUCATION, o valor 0 aparece no dataset mas não consta na documentação original.
Tipo de dados: Nominal
Valores válidos: 1 = Casado(a), 2 = Solteiro(a), 3 = Outros, 0 = Não documentado.
Valores distintos: 4
Menor valor: 0 | **Maior valor:** 3 | **Moda:** 2 (Solteiro — 53,2%)
Média: 1,55 | **Desvio-padrão:** 0,52 | **Mediana:** 2,00

▶️ AGE
O que representa: Idade do cliente em anos completos.
Tipo de dados: Numérico
Valores válidos: Valores inteiros positivos. No dataset: de 21 a 79 anos.
Valores distintos: 56
Menor valor: 21 | **Maior valor:** 79 | **Moda:** 29
Média: 35,49 | **Desvio-padrão:** 9,22 | **Mediana:** 34,00

▶️ PAY_0
O que representa: Status de pagamento do cliente no mês de setembro de 2005. Valores negativos indicam situações regulares, enquanto valores positivos indicam meses de atraso.
Tipo de dados: Ordinal

Valores válidos: -2 = Sem consumo no período, -1 = Pagou integralmente em dia, 0 = Uso de crédito rotativo (pagou o mínimo), 1 a 8 = Quantidade de meses em atraso.
Valores distintos: 11
Menor valor: -2 | **Maior valor:** 8 | **Moda:** 0 (Rotativo — 49,1%)
Média: -0,02 | **Desvio-padrão:** 1,12 | **Mediana:** 0,00

▶️ PAY_2
O que representa: Status de pagamento do cliente em agosto de 2005. Mesma escala de PAY_0.
Tipo de dados: Ordinal
Valores válidos: Mesmos valores de PAY_0: -2, -1, 0, e de 1 a 8.
Valores distintos: 11
Menor valor: -2 | **Maior valor:** 8 | **Moda:** 0 (Rotativo — 52,4%)
Média: -0,13 | **Desvio-padrão:** 1,20 | **Mediana:** 0,00

▶️ PAY_3
O que representa: Status de pagamento do cliente em julho de 2005. Mesma escala dos anteriores.
Tipo de dados: Ordinal
Valores válidos: Mesmos valores de PAY_0: -2, -1, 0, e de 1 a 8.
Valores distintos: 11
Menor valor: -2 | **Maior valor:** 8 | **Moda:** 0 (Rotativo — 52,5%)
Média: -0,17 | **Desvio-padrão:** 1,20 | **Mediana:** 0,00

▶️ BILL_AMT1
O que representa: Valor total da fatura do cartão de crédito em setembro de 2005, em NT$. Valores negativos podem ocorrer quando o cliente pagou além do valor da fatura anterior.
Tipo de dados: Numérico
Valores válidos: Valores inteiros (positivos ou negativos). No dataset: de -165.580 a 964.511 NT$.
Valores distintos: 22.723
Menor valor: -165.580 | **Maior valor:** 964.511 | **Moda:** 0
Média: 51.223,33 | **Desvio-padrão:** 73.635,86 | **Mediana:** 22.381,50

▶️ PAY_AMT1
O que representa: Valor pago pelo cliente na fatura de setembro de 2005, em NT$.
Tipo de dados: Numérico
Valores válidos: Valores inteiros não-negativos. No dataset: de 0 a 873.552 NT$.
Valores distintos: 7.943
Menor valor: 0 | **Maior valor:** 873.552 | **Moda:** 0
Média: 5.663,58 | **Desvio-padrão:** 16.563,28 | **Mediana:** 2.100,00

▶️ default payment next month
O que representa: Variável alvo (target). Indica se o cliente se tornou inadimplente no mês de outubro de 2005, ou seja, no mês seguinte ao último período observado.
Tipo de dados: Nominal (binário)
Valores válidos: 0 = Não inadimplente, 1 = Inadimplente.
Valores distintos: 2
Menor valor: 0 | **Maior valor:** 1 | **Moda:** 0 (Não inadimplente — 77,9%)
Média: 0,22 | **Desvio-padrão:** 0,42 | **Mediana:** 0,00

Evidências dos cálculos realizados:

A seguir, apresento as imagens que evidenciam o processo de análise. A tabela de estatísticas e os gráficos foram gerados em Python (pandas + matplotlib) a partir do arquivo XLS original.

Tabela resumo das estatísticas descritivas:

Estatísticas Descritivas das 11 Colunas Selecionadas

Coluna	Valores Distintos	Mínimo	Máximo	Moda	Média	Desvio Padrão	Mediana
LIMIT_BAL	81	10,000	1,000,000	50,000	167,484.32	129,747.66	140,000.00
SEX	2	1	2	2	1.60	0.49	2.00
EDUCATION	7	0	6	2	1.85	0.79	2.00
MARRIAGE	4	0	3	2	1.55	0.52	2.00
AGE	56	21	79	29	35.49	9.22	34.00
PAY_0	11	-2	8	0	-0.02	1.12	0.00
PAY_2	11	-2	8	0	-0.13	1.20	0.00
PAY_3	11	-2	8	0	-0.17	1.20	0.00
BILL_AMT1	22723	-165,580	964,511	0	51,223.33	73,635.86	22,381.50
PAY_AMT1	7943	0	873,552	0	5,663.58	16,563.28	2,100.00
default payment\nnext month	2	0	1	0	0.22	0.42	0.00

Gráficos de distribuição das principais colunas:

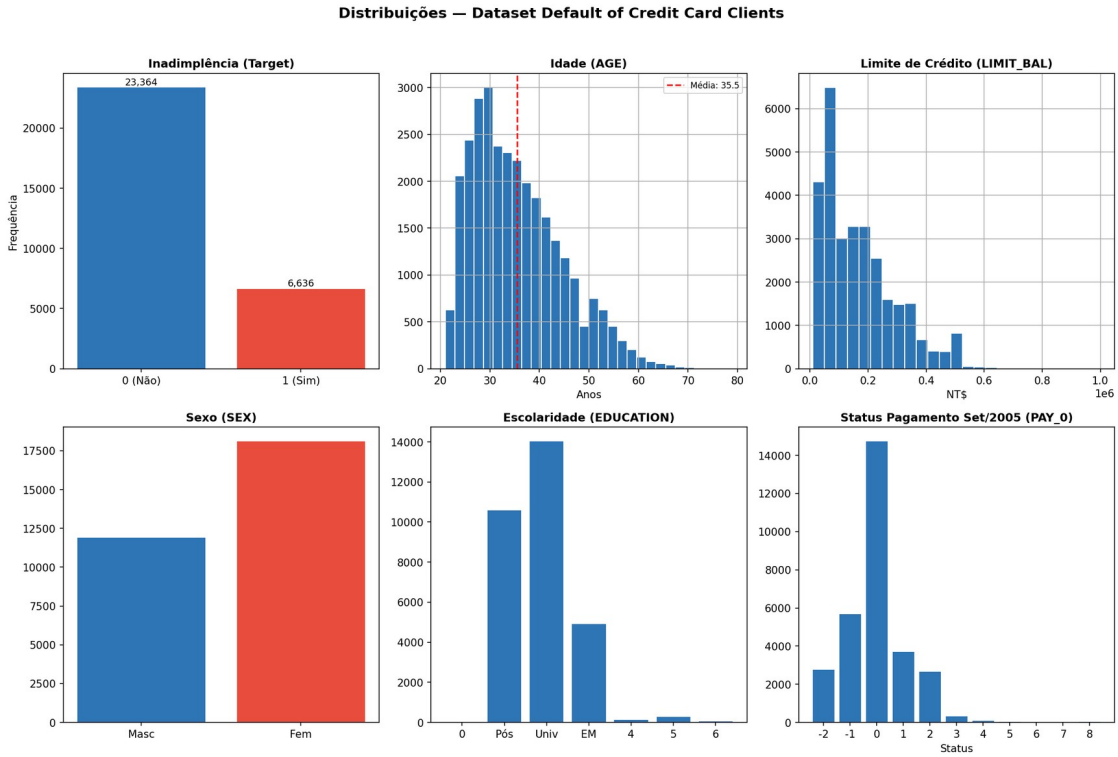

Código Python utilizado:

Código Python utilizado na análise

```python
import pandas as pd

df = pd.read_excel('default of credit card clients.xls', header=1)
print(f"Linhas: {df.shape[0]}, Colunas: {df.shape[1]}")
# Linhas: 30000, Colunas: 25

colunas = ['LIMIT_BAL', 'SEX', 'EDUCATION', 'MARRIAGE', 'AGE',
           'PAY_0', 'PAY_2', 'PAY_3', 'BILL_AMT1', 'PAY_AMT1',
           'default payment next month']

for col in colunas:
    s = df[col]
    print(f"\n--- {col} ---")
    print(f"Distintos: {s.nunique()}")
    print(f"Min: {s.min()}, Max: {s.max()}, Moda: {s.mode()[0]}")
    print(f"Media: {s.mean():.2f}, Std: {s.std():.2f}")
    print(f"Mediana: {s.median():.2f}")
    print(f"Nulos: {s.isnull().sum()}")

# Verificando valores nulos no dataset completo
print(f"\nTotal de nulos: {df.isnull().sum().sum()}")
# Total de nulos: 0

# Distribuicao do target
print(df['default payment next month'].value_counts())
# 0    23364 (77.9%)
# 1     6636 (22.1%)
```

Descrição da coluna alvo e potenciais aplicações:

A coluna alvo é **default payment next month**. Ela assume apenas dois valores: 0 para clientes que não ficaram inadimplentes e 1 para os que ficaram. No dataset, 23.364 clientes (77,9%) não deram default e 6.636 (22,1%) se tornaram inadimplentes, o que mostra um desbalanceamento típico de problemas de crédito.

A oportunidade de projeto que identifico aqui é a construção de um **modelo de classificação** que consiga prever, antes que aconteça, quais clientes têm maior chance de se tornarem inadimplentes. Na prática, isso permitiria que o banco (ou cooperativa) tomasse ações preventivas: reduzir o limite de quem tem risco alto, entrar em contato antes do vencimento, oferecer renegociação, ou revisar as políticas de concessão de crédito. Algoritmos como Regressão Logística, Random Forest ou XGBoost são bastante utilizados nesse tipo de problema.

O que justifica essa oportunidade é que o dataset traz tanto informações do perfil do cliente (idade, escolaridade, estado civil) quanto o comportamento real de pagamento ao longo de seis meses, o que permite ao modelo capturar padrões importantes. O desbalanceamento de classes (22% vs 78%) também torna o projeto didático, já que obriga a explorar técnicas como oversampling (SMOTE) ou ajuste de thresholds na fase de modelagem.

Link para acesso aos dados selecionados:

UCI (original): https://archive.ics.uci.edu/dataset/350/default+of+credit+card+clients
Kaggle: https://www.kaggle.com/datasets/uciml/default-of-credit-card-clients-dataset

Não foi necessário fazer nenhum recorte ou amostragem do dataset original. O arquivo XLS foi baixado diretamente do Kaggle e carregado no Python usando pandas (pd.read_excel com header=1, já que a primeira linha do arquivo contém nomes alternativos das colunas). Para carga no Orange Data Mining, exportei o dataset para CSV utilizando df.to_csv(), e o arquivo pode ser importado diretamente pelo widget File do Orange.

Uso de ferramentas de Inteligência Artificial:

Ferramenta utilizada: Claude (Anthropic).
Como foi empregada: Utilizei o Claude como apoio na busca e comparação de datasets disponíveis em repositórios públicos (UCI, Kaggle) e na estruturação do documento de entrega.

Grau de contribuição: A escolha do tema (risco de crédito), os códigos, a seleção final do dataset, a interpretação dos resultados e a redação do documento foram feitas por mim. A ferramenta serviu como apoio técnico e operacional.